

CENTRO UNIVERSITÁRIO SENAC

SANTO AMARO

PROJETO INTEGRADOR V:
APOIO DECISÓRIO AOS NEGÓCIOS

Bruno Costa Caiado

Felipe Augusto Santinho

Isabel Helena Hartmann

Paula Barros Ortiz

Thais Oliveira dos Santos

EAD - ENSINO À DISTÂNCIA

2025

Bruno Costa Caiado

Felipe Augusto Santinho

Isabel Helena Hartmann

Paula Barros Ortiz

Thais Oliveira dos Santos

PROJETO INTEGRADOR V:
APOIO DECISÓRIO AOS NEGÓCIOS

Projeto Integrador V – Fase 1
apresentado ao Centro Universitário Senac,
como exigência parcial para obtenção
de aprovação na disciplina Projeto Integrador V,
do curso de Banco de Dados.
Orientador (a): Gustavo Calixto

EAD - ENSINO À DISTÂNCIA

2025

RESUMO

O presente estudo propõe a análise das disparidades regionais na infraestrutura das escolas brasileiras com base nos microdados do Censo Escolar da Educação Básica 2024. O problema central reside na distribuição desigual de recursos físicos e tecnológicos, fator que compromete a equidade educacional e a qualidade do ensino, variando drasticamente entre as redes pública e privada e entre as macrorregiões do país. A partir de variáveis relacionadas à rede de ensino, busca-se compreender como fatores estruturais influenciam o acesso dos estudantes a ambientes educacionais adequados. Para isso, desenvolve-se um processo de ETL (Extração, Transformação e Carga), que garante a padronização, limpeza e consolidação dos dados, possibilitando a construção de indicadores comparáveis entre regiões e dependências administrativas. Os resultados esperados incluem a identificação de padrões de desigualdade, o cálculo de um índice médio de infraestrutura escolar e o apoio a decisões estratégicas para políticas públicas de educação.

Palavra-chave: infraestrutura escolar; desigualdade regional; Censo Escolar; educação básica; políticas públicas.

ABSTRACT

This study analyzes regional disparities in the infrastructure of Brazilian schools using microdata from the 2024 Basic Education School Census. The central issue lies in the unequal distribution of physical and technological resources, which undermines educational equity and teaching quality, with significant variations between public and private school networks and across the country's macro-regions. Based on variables related to school administration types, the study investigates how structural factors influence students' access to adequate learning environments. To achieve this, an ETL (Extraction, Transformation, and Loading) process is developed to ensure data standardization, cleaning, and consolidation, enabling the construction of indicators that are comparable across regions and administrative dependencies. Expected results include identifying inequality patterns, calculating an average school infrastructure index, and supporting strategic decision-making for educational public policies.

Keywords: school infrastructure; regional inequality; School Census; basic education; public policy.

Lista de Ilustrações

Figura 1 - Fluxograma do Processo ETL

Lista de Tabelas

Tabela 1 – Variáveis selecionadas da base do Censo Escolar (INEP, 2024)

SUMÁRIO

1. INTRODUÇÃO.....	1
1.1 Contextualização do tema.....	1
1.2 Justificativa.....	2
1.3 Objetivos gerais e específicos.....	3
2. FONTE DE DADOS.....	3
2.1 Origem e descrição.....	3
2.2 Estrutura da base.....	4
2.3 Relevância dos dados.....	6
2.4 Plano de tratamento (planejado).....	6
3. ATIVIDADES DE APOIO À DECISÃO.....	10
3.1 Entendimento do problema.....	10
3.2 Possibilidades de análise.....	10
3.3 Decisões possíveis.....	11
3.4 Potencial analítico e perguntas de negócio.....	11
4. PROCESSO ETL (PLANEJADO).....	12
4.1 Extração.....	12
4.2 Transformação.....	13
4.3 Carga.....	14
4.4 Ferramentas e justificativa.....	14
5. IMPLEMENTAÇÃO DA SOLUÇÃO ANALÍTICA.....	16
5.1 Disponibilização da Implementação no GitHub.....	16
5.2 Definição das Tecnologias Utilizadas.....	17
6. IMPLEMENTAÇÃO DO PROCESSO DE ETL.....	18
6.1 Extração dos Dados.....	19
6.2 Preparação e Organização dos Dados.....	19
6.3 Camada de Staging.....	19
6.4 Processo de Carga.....	20
6.5 Validação da Carga.....	20
7. ORGANIZAÇÃO DOS DADOS NO PIPELINE.....	21
8. CONSULTAS OLAP E ANÁLISE DOS DADOS.....	22
CONCLUSÃO.....	23
REFERÊNCIAS.....	24

1. INTRODUÇÃO

A infraestrutura escolar desempenha um papel fundamental na garantia de condições adequadas de ensino e aprendizagem. Elementos como saneamento básico, energia elétrica, equipamentos pedagógicos, conectividade e espaços físicos influenciam diretamente a qualidade da educação oferecida. No entanto, a distribuição desses recursos no Brasil ainda ocorre de forma desigual, refletindo disparidades históricas entre regiões, redes de ensino e contextos socioeconômicos.

Com base nos microdados do Censo Escolar 2024, este trabalho busca compreender como essas desigualdades se manifestam e quais fatores contribuem para a variação na disponibilidade de infraestrutura escolar ao longo do território nacional. A análise apoiada por processos de ETL e pela construção de indicadores permite não apenas descrever o cenário atual, mas também oferecer subsídios analíticos para políticas públicas voltadas à redução dessas disparidades.

1.1 Contextualização do tema

A educação básica brasileira, assegurada como direito fundamental pela Constituição Federal de 1988, enfrenta desafios estruturais que comprometem o pleno desenvolvimento dos estudantes. A qualidade da aprendizagem está diretamente relacionada à infraestrutura física e tecnológica disponível, pois ela influencia o ambiente pedagógico, o bem-estar dos alunos e as possibilidades de desenvolver competências essenciais no século XXI.

Escolas localizadas em áreas rurais, regiões menos desenvolvidas ou pertencentes às redes municipais frequentemente operam com limitações importantes. A infraestrutura escolar ultrapassa a dimensão da construção física e constitui parte central do processo educativo. Elementos como água potável, esgotamento sanitário, energia elétrica estável, conectividade de banda larga e laboratórios de informática são fundamentais tanto para a saúde pública quanto para a inclusão digital.

A ausência ou precariedade desses itens intensifica desigualdades pré-existentes, contribuindo para um ciclo de desvantagem que se reflete em indicadores de permanência, aprendizagem e desempenho. Em contraste, escolas da rede privada e instituições

localizadas em regiões mais desenvolvidas contam com melhores condições físicas e tecnológicas, ampliando as diferenças de oportunidades educacionais no país.

Nesse cenário, compreender a infraestrutura escolar como variável determinante da qualidade educacional é essencial para a construção de políticas de equidade. O Censo Escolar, por sua abrangência e caráter censitário, fornece a principal base de dados para este tipo de análise, permitindo mapear com precisão essas desigualdades.

1.2 Justificativa

A relevância deste estudo justifica-se pela necessidade de preencher uma lacuna empírica na análise da política educacional brasileira. A literatura demonstra que diferenças estruturais impactam diretamente o desempenho escolar, o bem-estar dos estudantes e a capacidade das escolas de implementar práticas pedagógicas eficazes. Embora a desigualdade de infraestrutura seja amplamente reconhecida, o mapeamento preciso dessa realidade e a criação de um indicador sintético comparável entre redes e regiões são etapas fundamentais para subsidiar políticas públicas baseadas em evidências. A ênfase exclusiva em métricas de desempenho, como o IDEB, pode mascarar fatores estruturais subjacentes, entre os quais a infraestrutura se destaca como elemento central.

O uso dos microdados do Censo Escolar 2024 é justificado por sua abrangência e elevada granularidade. Além disso, a metodologia proposta, centrada na construção de um Índice Médio de infraestrutura, oferece uma ferramenta analítica de interpretação simples e alta comparabilidade, servindo como referência para o monitoramento contínuo dos investimentos em infraestrutura nos próximos anos.

Adicionalmente, gestores públicos dependem de informações sistematizadas e comparáveis para planejar investimentos, direcionar recursos e acompanhar a efetividade das políticas educacionais. Ao propor um processo estruturado de tratamento dos microdados e a construção de indicadores, este estudo contribui para a elaboração de diagnósticos mais precisos, capazes de apoiar a tomada de decisão e promover maior transparência na gestão da infraestrutura escolar.

1.3 Objetivos gerais e específicos

Analisar as desigualdades regionais na infraestrutura das escolas brasileiras por meio dos microdados do Censo Escolar 2024, utilizando processos de ETL para construção de indicadores comparativos entre regiões, tipos de rede e localizações.

Objetivos Específicos

- Identificar as variáveis de infraestrutura mais críticas, com menor taxa de disponibilidade, nas escolas da rede pública de ensino.
- Desenvolver um índice sintético de infraestrutura escolar (Índice Médio de Infraestrutura) capaz de resumir as condições físicas e tecnológicas das escolas em um único valor comparável.
- Comparar o Índice Médio de Infraestrutura entre as escolas urbanas e rurais, e entre as diferentes dependências administrativas (Federal, Estadual, Municipal e Privada).
- Identificar padrões de desigualdade e áreas prioritárias para formulação de políticas públicas.
- Gerar dados desagregados (tabelas e visualizações) que auxiliem gestores na identificação de regiões e tipologias de escolas que demandam prioridade imediata na alocação de investimentos públicos.

2. FONTE DE DADOS

2.1 Origem e descrição

O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) é o órgão responsável pela coleta, sistematização e divulgação de dados oficiais sobre a educação brasileira. Entre suas principais iniciativas está o Censo Escolar da Educação Básica, realizado anualmente em parceria com as secretarias estaduais e municipais de educação. Trata-se da mais ampla pesquisa estatística sobre a educação básica no país, abrangendo todas as escolas públicas e particulares que oferecem educação infantil, ensino fundamental ou ensino médio. As informações coletadas compõem os microdados do Censo

Escolar, disponibilizados em formato aberto no portal do INEP, em conformidade com as políticas federais de transparência de dados.

No caso específico do Censo Escolar 2024, os arquivos estão disponíveis para download na seção de Dados Abertos do INEP, hospedada no portal oficial do governo brasileiro. O conjunto de microdados é formado por diferentes arquivos, normalmente organizados por nível de informação (escolas, turmas, docentes e matrículas) e acompanhados por um dicionário de variáveis que orienta a interpretação dos códigos utilizados. Esses arquivos seguem o formato CSV (Comma-Separated Values), amplamente adotado para intercâmbio de dados. Cada linha representa uma unidade observacional, no caso deste estudo, uma escola, e cada coluna corresponde a uma variável descritiva, como localização, infraestrutura ou dependência administrativa. Por sua estrutura simples e interoperável, o formato CSV permite leitura em softwares estatísticos, linguagens de programação (como Python e R) e planilhas eletrônicas, facilitando análises quantitativas em larga escala.

2.2 Estrutura da base

A base de microdados é estruturada para permitir investigações detalhadas sobre as condições das escolas brasileiras. No contexto da análise da infraestrutura escolar e desigualdade regional, as colunas mais relevantes são aquelas que identificam a localização, o tipo de administração e as condições físicas de cada unidade.

Entre as variáveis essenciais, destacam-se:

- **NO_REGIAO**, **SG_UF** e **NO_MUNICIPIO**, que indicam a posição geográfica da escola e possibilitam a comparação entre regiões;
- **TP_DEPENDENCIA**, que distingue escolas federais, estaduais, municipais e privadas, servindo de base para a divisão público–privado;
- **TP_LOCALIZACAO**, que diferencia zonas urbanas e rurais, fator que influencia diretamente a disponibilidade de infraestrutura.

No campo da infraestrutura, variáveis que indicam o acesso a serviços básicos:

- **IN_AGUA_REDE_PUBLICA**, **IN_ESGOTO_REDE_PUBLICA**, **IN_ENERGIA_REDE_PUBLICA** e **IN_COLETA_LIXO** refletem o

acesso a serviços públicos básicos, que ainda apresentam cobertura desigual no território nacional.

- **IN_INTERNET, IN_BANDA_LARGA, IN_LABORATORIO_INFORMATICA, IN_BIBLIOTECA e IN_QUADRA_ESPORTES** representam condições pedagógicas e tecnológicas que impactam diretamente a qualidade do ensino e o ambiente de aprendizagem.

Quanto às características físicas das escolas, um conjunto relevante de informações presentes nos microdados refere-se às salas de aula efetivamente utilizadas. As variáveis disponíveis são:

- **QT_SALAS_UTILIZADAS_DENTRO** – salas utilizadas dentro da estrutura principal da escola;
- **QT_SALAS_UTILIZADAS_FORA** – salas utilizadas em anexos ou espaços externos;
- **QT_SALAS_UTILIZADAS** – total de salas em uso para atividades pedagógicas;
- **QT_SALAS_UTILIZA_CLIMATIZADAS** – salas utilizadas que possuem climatização;
- **QT_SALAS_UTILIZADAS_ACESSIVEIS** – salas utilizadas com condições adequadas de acessibilidade.

Essas variáveis permitem construir indicadores de densidade e de uso do espaço escolar, possibilitando identificar diferenças estruturais entre redes públicas e privadas, bem como entre regiões. Indicadores como a razão entre matrículas e salas utilizadas revelam potenciais pressões sobre a infraestrutura física.

Para mensurar o porte das escolas e calcular tais indicadores, utilizam-se as variáveis de matrícula disponibilizadas nos microdados (dado que o Censo Escolar registra matrículas, e não alunos individualmente). Assim, indicadores de demanda serão baseados nas seguintes variáveis:

- Educação básica: **QT_MAT_BAS**
- Educação infantil: **QT_MAT_INF, QT_MAT_INF_CRE, QT_MAT_INF_PRE**
- Ensino fundamental: **QT_MAT_FUND**
- Ensino fundamental – anos iniciais: **QT_MAT_FUND_AI** e suas subdivisões
- Ensino fundamental – anos finais: **QT_MAT_FUND_AF** e suas subdivisões

- Ensino médio: **QT_MAT_MED**
- Ensino médio propedêutico: **QT_MAT_MED_PROP** e suas subdivisões

2.3 Relevância dos dados

A relevância desses dados para o tema proposto é ampla e multifacetada. O Censo Escolar constitui uma das poucas fontes que abrangem a totalidade do sistema educacional brasileiro, o que confere legitimidade, consistência e alcance nacional à análise. Além disso, a combinação entre variáveis geográficas e administrativas permite identificar padrões regionais de desigualdade, evidenciando como fatores socioeconômicos e estruturais influenciam o acesso à infraestrutura educacional. A comparação entre escolas públicas e particulares também revela assimetrias históricas de investimento e qualidade, refletidas tanto no ambiente físico quanto nas oportunidades pedagógicas oferecidas aos estudantes.

Em síntese, os microdados do Censo Escolar 2024 representam uma fonte de informação essencial para estudos que buscam compreender a relação entre infraestrutura escolar e desigualdade regional. Seu formato acessível, abrangência nacional e nível de detalhamento tornam possível mapear, com precisão estatística, as lacunas existentes entre diferentes tipos de escola e as desigualdades que se reproduzem nas diversas regiões do país. Dessa forma, o uso dessa base de dados não apenas fortalece o debate acadêmico, mas também contribui para o aprimoramento das políticas de educação básica e para a construção de um sistema educacional mais justo e equilibrado.

2.4 Plano de tratamento (planejado)

A análise da infraestrutura escolar e da desigualdade regional no Brasil requer não apenas acesso a bases de dados abrangentes, mas também um processo rigoroso de tratamento e preparação dos dados. A etapa de ETL (Extração, Transformação e Carga) é o alicerce metodológico que assegura a confiabilidade dos resultados e a consistência das interpretações estatísticas. Essa fase envolve três dimensões complementares: limpeza, filtragem e padronização dos dados, culminando na construção de indicadores sintéticos que permitam mensurar de forma comparável a infraestrutura educacional entre redes públicas e particulares.

A primeira etapa, de extração, consiste em importar os microdados do Censo Escolar 2024, disponibilizados pelo INEP no formato .csv. Nessa fase inicial, é essencial garantir a

correta leitura dos delimitadores, codificações e tipos de variáveis, conforme especificado no dicionário de dados que acompanha o conjunto de microdados. A extração deve preservar a integridade das informações originais, assegurando que cada linha represente uma escola e cada coluna corresponda a uma de suas características institucionais. Isso é fundamental para manter a representatividade dos registros e possibilitar análises desagregadas por região e dependência administrativa

Em seguida, realiza-se a etapa de limpeza dos dados, voltada à detecção e ao tratamento de inconsistências, valores ausentes e duplicidades. Variáveis binárias, como **IN_BIBLIOTECA**, **IN_INTERNET** e **IN_ESGOTO_REDE_PUBLICA**, podem apresentar diferenças de codificação entre edições do Censo Escolar, como "0 = Não", "1 = Sim" ou "0/1", sendo necessária sua recodificação para um formato padronizado. Registros com informações incompletas devem ser avaliados conforme sua relevância, podendo ser removidos ou receber categorização específica. A limpeza inclui ainda a conversão de tipos de variáveis e a eliminação de colunas que não são essenciais ao escopo do estudo, reduzindo o volume de dados e otimizando o processamento.

A etapa de filtragem e padronização tem como foco selecionar variáveis diretamente relacionadas ao problema de pesquisa, como infraestrutura escolar, dependência administrativa e localização geográfica. Nesse processo, serão mantidas variáveis como **TP_DEPENDENCIA**, **NO_REGIAO**, **SG_UF**, **IN_AGUA_REDE_PUBLICA**, **IN_ENERGIA_REDE_PUBLICA**, **IN_LABORATORIO_INFORMATICA**, **IN_BANDA_LARGA** e **IN_QUADRA_ESPORTES**, entre outras. A padronização dos nomes das colunas em formato uniforme, como letras minúsculas e separadas por sublinhado, facilita o uso em linguagens de programação e reforça a transparência metodológica.

Após a estruturação e limpeza da base, inicia-se a fase de transformação analítica, na qual são calculados indicadores compostos de infraestrutura e estatísticas descritivas agregadas. Cada variável binária é transformada em valor numérico (1 = possui, 0 = não possui), permitindo o cálculo do índice médio de infraestrutura por escola, região e rede. O índice é obtido pela média simples das variáveis selecionadas, representando a proporção de itens de infraestrutura disponíveis. Posteriormente, essas médias são consolidadas por região geográfica e por dependência administrativa, possibilitando comparações diretas entre diferentes contextos educacionais.

A fase final, de carga, consiste em armazenar a base já tratada em um formato adequado para análise estatística e visualização, como CSV simplificado ou XLSX. Essa

versão consolidada servirá de insumo para etapas subsequentes de exploração gráfica, regressão e comparação regional. Também é importante manter registros documentais das transformações realizadas para assegurar auditoria, rastreabilidade e fidelidade às informações originais.

Do ponto de vista conceitual, a etapa de ETL não é apenas um procedimento técnico, mas uma fase crítica do método científico aplicado à pesquisa educacional. É nessa etapa que se define a qualidade da evidência empírica, influenciando diretamente a validade das conclusões do estudo. Um processo de ETL bem estruturado transforma dados brutos, extensos e fragmentados em informações robustas, capazes de sustentar diagnósticos precisos e apoiar políticas públicas mais direcionadas. No contexto brasileiro, marcado por disparidades persistentes entre redes e regiões, a execução cuidadosa dessa fase é indispensável para revelar de forma clara e consistente as dimensões reais da desigualdade educacional.

Tabela 1 – Variáveis selecionadas da base do Censo Escolar (INEP, 2024)

Dicionário de Dados - Infraestrutura Escolar

Variáveis do Censo Escolar para análise de desigualdades educacionais no Brasil

COLUNA	DESCRIÇÃO	JUSTIFICATIVA
CO_REGIAO / NO_REGIAO	Código e nome da grande região (Norte, Nordeste, Sudeste, Sul, Centro-Oeste)	Permite estruturar a análise territorial, evidenciando desigualdades macro regionais no acesso e na qualidade da infraestrutura escolar.
CO_UF / SG_UF	Código e sigla da Unidade da Federação	Possibilitam comparações entre estados, detalhando variações internas às regiões e desigualdades interestaduais.
CO_MUNICIPIO / NO_MUNICIPIO	Código e nome do município	Aprofundam o recorte territorial, permitindo mapear desigualdades locais e diferenças entre redes municipais e estaduais dentro de uma mesma região.
TP_DEPENDENCIA	Tipo de dependência administrativa da escola (1=federal; 2=estadual; 3=municipal; 4=privada)	Essencial para comparar infraestrutura entre redes públicas e privadas, principal eixo da análise proposta.
TP_REDE_LOCAL	Tipo de rede local à qual a escola pertence	Complementa a variável anterior, permitindo observar nuances de gestão e capilaridade institucional.
IN_AGUA_REDE_PUBLICA	Indica se a escola possui ligação com rede pública de água	Representa o acesso a infraestrutura sanitária básica, indicador direto de equidade e qualidade ambiental nas escolas.
IN_ESGOTO_REDE_PUBLICA	Indica se a escola possui ligação à rede pública de esgoto	Outro indicador fundamental de saneamento e salubridade, correlato à saúde e ao bem-estar dos alunos e funcionários.
IN_ENERGIA_REDE_PUBLICA	Indica se há fornecimento de energia elétrica por rede pública	Infraestrutura indispensável para o funcionamento adequado da escola e para a utilização de recursos tecnológicos.
IN_INTERNET / IN_BANDA_LARGA / IN_ACESSO_INTERNET_COMPUTADOR	Indicadores de conectividade e acesso digital	Expressam a inserção tecnológica das escolas — variável decisiva na qualidade do ensino e na redução de desigualdades educacionais contemporâneas.
IN_BIBLIOTECA / IN_LABORATORIO_INFORMATICA / IN_LABORATORIO_Ciencias	Presença de equipamentos pedagógicos estruturantes	Refletem oportunidades de aprendizagem diferenciadas; a ausência desses recursos tende a reproduzir desigualdades regionais e institucionais.
IN_BANHEIRO / IN_BANHEIRO_PNE / IN_BANHEIRO_FUNCIONARIOS	Existência e adequação de instalações sanitárias	Indicadores de infraestrutura física mínima e de inclusão (no caso de banheiros adaptados para PNE), refletindo políticas de acessibilidade e dignidade.
IN_COZINHA / IN_REFEITORIO / IN_ALMOXARIFADO	Estruturas de apoio à gestão e à alimentação escolar	Essenciais para avaliar o ambiente de acolhimento, sobretudo nas redes públicas que oferecem alimentação escolar regular.
IN_QUADRA_ESPORTES / IN_PARQUE_INFANTIL / IN_AREA_VERDE / IN_PATIO_COBERTO	Infraestrutura física voltada ao lazer, esporte e convivência	Componentes relevantes para a qualidade do ambiente escolar e o desenvolvimento integral dos estudantes.

Territorial Administrativa Infraestrutura Básica Tecnologia Pedagógica Sanitária Apoio Lazer

Fonte: Elaborada pelos autores (2025).

3. ATIVIDADES DE APOIO À DECISÃO

3.1 Entendimento do problema

O problema central identificado refere-se às desigualdades na infraestrutura escolar brasileira, que variam significativamente entre regiões, redes de ensino (pública e privada) e tipos de localização (urbana e rural). Essas desigualdades afetam diretamente as condições de ensino e aprendizagem, dificultando o acesso equitativo a recursos essenciais, como saneamento, energia elétrica, laboratórios, conectividade e espaços adequados.

A análise proposta busca compreender esse cenário a partir dos microdados do Censo Escolar 2024, oferecendo uma visão mais clara de como essas diferenças se distribuem pelo território nacional. Essa etapa inicial permite delimitar o escopo do estudo, identificar os fatores que impactam a qualidade da infraestrutura e estabelecer a base para as análises subsequentes.

3.2 Possibilidades de análise

Com os dados selecionados na etapa Fonte de Dados e tratados no Processo ETL (Etapa 3), diversas possibilidades de análise se tornam viáveis, tais como:

- Comparações regionais, permitindo identificar as regiões com piores e melhores condições de infraestrutura.
- Comparações por dependência administrativa, avaliando diferenças entre escolas federais, estaduais, municipais e privadas.
- Análise urbano x rural, verificando como a localização influencia o acesso a recursos essenciais.
- Construção de indicadores sintéticos, como o índice médio de infraestrutura, que resume múltiplos itens em um único valor comparável.
- Mapeamentos e visualizações, com a criação de tabelas, gráficos e mapas que facilitam a interpretação dos resultados.
- Análises temporais futuras, estabelecendo uma linha de base para monitorar melhorias ou retrocessos em censos posteriores.

Essas possibilidades ampliam o potencial do projeto ao transformar dados brutos em informações claras, comparáveis e estrategicamente úteis.

3.3 Decisões possíveis

A partir das análises geradas, é possível apoiar decisões nos seguintes eixos:

- Priorização de investimentos em infraestrutura escolar, identificando regiões, redes ou localidades com maiores déficits.
- Formulação de políticas públicas segmentadas, como programas voltados para escolas rurais, municipais ou de regiões específicas.
- Planejamento de expansão de serviços públicos, como energia elétrica, internet banda larga e saneamento básico, direcionados a áreas mais carentes.
- Alocação de recursos educacionais com base no índice de infraestrutura e nos indicadores específicos levantados.
- Monitoramento de metas e resultados, utilizando os indicadores produzidos para avaliar a efetividade das políticas ao longo do tempo.
- Promoção de transparência e advocacy, permitindo que gestores e sociedade civil acompanhem as desigualdades de forma clara e objetiva.

Tais decisões representam aplicações práticas e diretas dos resultados obtidos pela análise dos dados.

3.4 Potencial analítico e perguntas de negócio

O potencial analítico do projeto reside na capacidade de transformar microdados complexos em informações estratégicas, capazes de orientar gestores, pesquisadores e formuladores de políticas públicas. A construção de indicadores, aliada à padronização e ao tratamento dos dados, permite análises profundas sobre disparidades estruturais no sistema educacional.

Com base nisso, surgem as seguintes perguntas de negócio que podem ser respondidas pelo estudo:

1. Quais regiões do país apresentam as piores condições de infraestrutura escolar?
2. Quais diferenças existem entre as escolas públicas e privadas no acesso a recursos essenciais?
3. Como a localização, urbana ou rural, impacta a qualidade da infraestrutura disponível?
4. Quais tipos de infraestrutura são mais críticos no contexto brasileiro, como água, energia, internet e laboratórios?

5. Como o índice médio de infraestrutura varia entre estados, regiões e dependências administrativas?
6. Quais áreas devem receber prioridade em políticas e investimentos públicos?

4. PROCESSO ETL (PLANEJADO)

O processo de ETL (Extração, Transformação e Carga) representa uma etapa fundamental na construção da base de dados deste estudo, pois define como as informações coletadas serão preparadas e organizadas para permitir análises consistentes. A partir dos microdados do Censo Escolar da Educação Básica 2024, pretende-se desenvolver um fluxo estruturado que assegure a integridade, a padronização e a qualidade dos dados utilizados.

Essa etapa envolve o planejamento de três procedimentos complementares:

- Extração: responsável pela obtenção e leitura dos arquivos originais;
- Transformação: voltada à limpeza, filtragem e recodificação das variáveis;
- Carga: etapa na qual os dados tratados serão armazenados em formato adequado à análise estatística e à visualização de resultados.

O objetivo é garantir que as informações sobre infraestrutura, localização e dependência administrativa das escolas sejam convertidas em indicadores claros e comparáveis, possibilitando a identificação de desigualdades regionais e estruturais no sistema educacional brasileiro.

4.1 Extração

A etapa de extração consiste na obtenção e leitura dos microdados do Censo Escolar da Educação Básica 2024, disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) em formato CSV. Os arquivos serão acessados diretamente por meio do portal de dados abertos do INEP, garantindo autenticidade e integridade das informações utilizadas no estudo.

O conjunto de microdados é composto por diferentes arquivos, organizados por nível de informação (escolas, turmas, docentes e matrículas) e acompanhados de um dicionário de variáveis que orienta a interpretação dos campos e códigos utilizados. Para a presente

análise, serão extraídos os dados referentes às escolas, pois são esses arquivos que reúnem as variáveis relacionadas à infraestrutura física, tecnológica e administrativa.

A seleção abrangerá variáveis como **NO_REGIAO**, **SG_UF**, **TP_DEPENDENCIA**, **IN_INTERNET**, **IN_BIBLIOTECA**, **IN_LABORATORIO_INFORMATICA**, **IN_ENERGIA_REDE_PUBLICA** e **IN_QUADRA_ESPORTES**, entre outras, que permitem a análise comparativa entre regiões e redes de ensino. Essa etapa busca garantir que os dados sejam coletados de forma completa e estruturada, preservando representatividade e consistência para as fases subsequentes do processo de ETL.

4.2 Transformação

A etapa de transformação corresponde ao momento em que os dados extraídos passam por procedimentos de limpeza, filtragem e padronização, assegurando a consistência e a qualidade das informações que serão analisadas. O objetivo é eliminar duplicidades, tratar valores ausentes, corrigir inconsistências e preparar as variáveis para posterior cálculo de indicadores.

As variáveis selecionadas, provenientes dos microdados do Censo Escolar da Educação Básica 2024, serão recodificadas conforme o dicionário de dados disponibilizado pelo INEP, garantindo uniformidade na interpretação dos valores. Variáveis binárias, como **IN_INTERNET**, **IN_BIBLIOTECA**, **IN_LABORATORIO_INFORMATICA**, **IN_ENERGIA_REDE_PUBLICA** e **IN_AGUA_REDE_PUBLICA**, serão convertidas para o formato numérico, em que o valor 1 representará presença e o valor 0 ausência. Essa padronização possibilitará o cálculo de médias e a construção de índices comparativos entre diferentes redes de ensino e regiões do país.

Durante a transformação, serão removidos registros com informações incompletas sobre localização ou dependência administrativa, a fim de evitar distorções nos resultados. Também serão excluídas colunas que não apresentem relevância direta para o tema do estudo, reduzindo o volume de dados e otimizando o processamento. Por fim, será criado um índice médio de infraestrutura escolar, calculando a partir da média das variáveis binárias relacionadas à presença de recursos básicos e pedagógicos. Esse índice servirá como indicador quantitativo do nível de infraestrutura disponível em cada escola, permitindo comparações entre escolas públicas e particulares e entre diferentes regiões geográficas.

4.3 Carga

A etapa de carga corresponde ao momento em que os dados transformados são organizados e armazenados em formato adequado para análise e visualização. Após os procedimentos de limpeza, filtragem e padronização, a base consolidada será exportada em formato CSV simplificado, preservando apenas as variáveis necessárias para as análises propostas.

Essa versão tratada dos dados permitirá a integração com ferramentas de análise estatística e de visualização, como Power BI, Excel ou Python, viabilizando a construção de painéis e relatórios que ilustrem as desigualdades regionais de infraestrutura escolar. A etapa da carga será planejada para garantir a integridade e a rastreabilidade das informações, assegurando que cada registro possa ser associado com precisão à escola correspondente.

A estrutura final possibilitará a realização de análises comparativas entre escolas públicas e particulares, bem como entre diferentes regiões e unidades federativas. Além disso, o armazenamento em formato padronizado facilitará atualizações futuras da base, permitindo a replicação do processo em outros períodos do Censo Escolar e ampliando as possibilidades de análise nas etapas seguintes do projeto.

4.4 Ferramentas e justificativa

O processo de ETL planejado será desenvolvido com o uso de ferramentas amplamente reconhecidas pela eficiência e pela flexibilidade na manipulação de dados. A escolha dos recursos tecnológicos considera critérios de acessibilidade, compatibilidade com arquivos em formato CSV e facilidade de integração entre as etapas de extração, transformação e carga.


A linguagem Python será utilizada como base para o tratamento dos dados, por meio das bibliotecas pandas e numpy, que possibilitam a leitura, a limpeza e a transformação de grandes volumes de informações de forma precisa e automatizada. Essas bibliotecas oferecem recursos adequados para a padronização das variáveis e o cálculo do índice médio de infraestrutura escolar, o que garante maior confiabilidade nas etapas subsequentes do processo analítico.

Para a fase de carga e visualização, será empregado o Power BI, que permite a criação de painéis dinâmicos, gráficos interativos e comparações entre regiões e tipos de rede escolar. O Excel também será utilizado como ferramenta auxiliar para conferência de

dados e validação dos resultados obtidos, devido à sua interface acessível e capacidade de análise tabular.

A escolha dessas ferramentas justifica-se pela combinação entre simplicidade e desempenho, proporcionando um ambiente completo para o desenvolvimento do processo de ETL e para o suporte às análises que serão realizadas nas etapas seguintes do projeto.

Figura 1: Fluxograma do Processo ETL



Fonte: Elaborada pelos autores (2025).

5. IMPLEMENTAÇÃO DA SOLUÇÃO ANALÍTICA

Após a etapa inicial de planejamento metodológico e definição do processo de ETL, iniciou-se a segunda fase do projeto, voltada à implementação técnica da solução de apoio à decisão. Nessa etapa foram definidas as tecnologias utilizadas, estruturado o ambiente de dados e implementado o pipeline de ingestão e organização dos microdados do Censo Escolar 2024.

O objetivo dessa fase foi transformar os dados brutos disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) em uma base relacional estruturada, capaz de suportar consultas analíticas e operações de processamento analítico online (OLAP).

5.1 Disponibilização da Implementação no GitHub

A implementação prática do pipeline de dados desenvolvido neste projeto encontra-se disponibilizada em repositório público no GitHub, permitindo a consulta do código utilizado no processo de ingestão, organização e preparação dos dados.

Nesse repositório estão disponíveis os scripts responsáveis pela execução do processo de ETL, bem como a documentação técnica da arquitetura da solução analítica implementada. A disponibilização do código contribui para a transparência metodológica do projeto, permitindo que outros pesquisadores ou analistas de dados possam compreender as etapas utilizadas no tratamento e organização dos dados.

Além disso, a disponibilização da implementação em ambiente público permite garantir a reprodutibilidade do processo analítico, possibilitando que o pipeline de dados seja executado novamente a partir da fonte original de dados.

O repositório do projeto pode ser acessado no seguinte endereço:

https://github.com/thaismarino/Infraestrutura_Escolar_e_Desigualdade_Regional

Nesse repositório encontram-se os códigos responsáveis pela leitura do arquivo de microdados, preparação inicial dos dados e carga das informações no banco de dados relacional utilizado no projeto.

5.2 Definição das Tecnologias Utilizadas

A implementação da solução analítica exigiu a seleção de ferramentas capazes de lidar com grandes volumes de dados, garantindo integridade, organização e flexibilidade para análise exploratória.

A arquitetura tecnológica adotada no projeto foi composta pelos seguintes elementos:

Banco de Dados Relacional

O sistema gerenciador de banco de dados utilizado foi o MySQL, escolhido como ambiente central de armazenamento e organização das informações processadas.

A escolha do MySQL se justifica pela sua ampla adoção em projetos de análise de dados, alto desempenho em operações de leitura e compatibilidade com diversas ferramentas de análise e visualização de dados.

Além disso, o modelo relacional permite organizar as variáveis educacionais de forma estruturada, facilitando a criação de consultas analíticas e a construção de indicadores comparativos entre diferentes regiões do país.

Processo de ETL

Para a implementação do processo de ETL foram utilizadas as seguintes ferramentas:

- Python
- Biblioteca Pandas
- SQLAlchemy

A linguagem Python foi utilizada para automatizar as etapas de leitura, tratamento inicial e organização dos dados provenientes do arquivo CSV do Censo Escolar.

A biblioteca Pandas foi responsável pela manipulação dos dados em formato tabular, permitindo selecionar colunas relevantes, organizar as informações e preparar a estrutura dos dados antes da carga no banco relacional.

Já o SQLAlchemy foi utilizado para estabelecer a conexão entre o ambiente Python e o banco de dados MySQL, permitindo a execução automatizada da carga dos registros.

Ferramenta de Gerenciamento de Banco de Dados

Durante o desenvolvimento do projeto foi utilizada a ferramenta DBeaver, que permite realizar consultas SQL, validar a estrutura das tabelas e verificar a integridade dos dados carregados no banco de dados.

Essa ferramenta foi utilizada principalmente para:

- validação da carga de dados
- execução de consultas analíticas
- verificação da estrutura das tabelas

Ferramenta de Visualização de Dados

Para a etapa de análise e visualização foi utilizado o Power BI, ferramenta amplamente utilizada em ambientes corporativos para apoio à tomada de decisão.

Com o Power BI foi possível desenvolver painéis interativos e realizar operações analíticas do tipo OLAP, permitindo explorar os dados em diferentes níveis de agregação, como:

- região
- estado
- dependência administrativa
- localização urbana ou rural

6. IMPLEMENTAÇÃO DO PROCESSO DE ETL

A implementação do processo de ETL foi responsável por estruturar e disponibilizar os microdados do Censo Escolar 2024 em um ambiente relacional organizado, permitindo sua utilização em análises analíticas e consultas OLAP.

O pipeline de dados foi estruturado seguindo uma arquitetura sequencial composta pelas etapas de extração, preparação estrutural e carga no banco de dados.

O fluxo geral do processo pode ser descrito da seguinte forma:

Arquivo CSV (microdados do INEP) → leitura e tratamento em Python → conexão com banco de dados → carga em tabela relacional.

Essa arquitetura permite separar claramente a etapa de ingestão de dados da etapa analítica, garantindo maior controle sobre o pipeline de dados.

6.1 Extração dos Dados

A etapa de extração consistiu na leitura do arquivo original de microdados do Censo Escolar 2024, disponibilizado pelo INEP em formato CSV.

O arquivo possui as seguintes características técnicas:

- formato CSV
- separador de campos ponto e vírgula (;)
- codificação de caracteres latin-1

Devido ao grande volume de registros presentes na base de dados, foi necessário utilizar técnicas de leitura seletiva de colunas, reduzindo o consumo de memória e aumentando a eficiência do processamento.

A leitura do arquivo foi realizada utilizando a função `read_csv()` da biblioteca Pandas, com seleção explícita das colunas relevantes para o projeto.

6.2 Preparação e Organização dos Dados

Após a leitura dos dados, foi realizada a preparação estrutural das informações, etapa responsável por organizar os dados antes da sua inserção no banco relacional.

Durante essa etapa foram executadas as seguintes atividades:

- seleção das variáveis relevantes para o estudo
- organização da estrutura do DataFrame
- inferência automática de tipos de dados
- preparação do conjunto de dados para inserção no banco

É importante destacar que, nessa fase, não foram aplicadas transformações analíticas complexas, agregações ou regras de negócio.

A camada de dados resultante dessa etapa mantém as informações em estado próximo ao original, preservando a granularidade dos microdados.

6.3 Camada de Staging

Como parte da arquitetura do pipeline de dados, foi implementada uma camada intermediária denominada staging.

Essa camada tem como objetivo armazenar os dados extraídos da fonte original em um ambiente relacional preliminar, permitindo maior controle sobre o processo de ingestão.

A tabela criada para essa finalidade foi denominada:

stg_escolas_2024

Essa tabela funciona como repositório intermediário dos microdados, mantendo os registros em estado próximo ao original e permitindo a realização de validações antes da construção da camada analítica.

Entre as principais características dessa camada destacam-se:

- ausência de modelagem dimensional
- inexistência de indicadores calculados
- estrutura próxima aos dados originais
- processo idempotente de carga

Essa abordagem é amplamente utilizada em projetos de engenharia de dados, pois permite separar claramente as etapas de ingestão e transformação analítica.

6.4 Processo de Carga

A carga dos dados no banco relacional foi realizada por meio do método `to_sql()` da biblioteca Pandas, que permite inserir registros diretamente em tabelas de bancos de dados relacionais.

A operação foi executada utilizando inserção em lotes, técnica que reduz o consumo de memória e melhora o desempenho da carga.

Durante esse processo foram executados automaticamente comandos SQL do tipo INSERT, responsáveis por persistir os registros na tabela de staging.

A carga foi configurada de forma idempotente, ou seja, a tabela é recriada a cada execução do pipeline, evitando duplicação de registros.

6.5 Validação da Carga

Após a execução do processo de carga, foi realizada a validação da base populada utilizando consultas SQL no ambiente DBeaver.

A principal consulta utilizada para verificação da integridade da carga foi:

SELECT COUNT(*) FROM stg_escolas_2024;

Além dessa verificação, foram realizadas inspeções amostrais das linhas e conferência da estrutura das colunas.

Esses procedimentos permitiram confirmar que os dados foram inseridos corretamente e que a estrutura da tabela estava consistente com a base original.

7. ORGANIZAÇÃO DOS DADOS NO PIPELINE

Para garantir organização metodológica e rastreabilidade do pipeline, os dados do projeto foram organizados em diferentes níveis de manipulação ao longo do processo de ETL.

Fonte de Dados Original

A fonte primária de dados corresponde ao arquivo de microdados do Censo Escolar 2024 disponibilizado pelo INEP em formato CSV.

Esse arquivo representa a base original utilizada no processo de ingestão.

Tabela de Staging

Após a etapa de extração e preparação inicial, os dados foram carregados no banco relacional MySQL por meio da tabela:

stg_escolas_2024

Essa tabela funciona como camada intermediária de armazenamento, permitindo validar os dados antes da realização das análises.

Camada Analítica

A partir da tabela de staging são executadas consultas SQL responsáveis pela geração das análises exploratórias e dos indicadores utilizados no estudo.

Essa camada permite organizar os dados de forma adequada para análises comparativas e construção de visualizações analíticas.

8. CONSULTAS OLAP E ANÁLISE DOS DADOS

A etapa final da implementação consistiu no desenvolvimento de consultas analíticas baseadas em operações OLAP, com o objetivo de identificar padrões de desigualdade na infraestrutura escolar brasileira.

As consultas foram desenvolvidas utilizando SQL e organizadas em três perspectivas analíticas principais:

- estrutura por unidade escolar
- impacto ponderado por matrícula
- pressão estrutural sobre a infraestrutura

Essa abordagem permite analisar o problema de forma mais completa, considerando não apenas o número de escolas com determinada infraestrutura, mas também o número de estudantes afetados pelas desigualdades estruturais.

CONCLUSÃO

Este projeto teve como objetivo analisar as desigualdades regionais na infraestrutura das escolas brasileiras com base nos microdados do Censo Escolar da Educação Básica de 2024. Para isso, foi desenvolvido um processo estruturado de ETL que permitiu transformar grandes volumes de dados brutos em uma base organizada e adequada para análises comparativas.

Na primeira etapa do projeto foram definidos o problema de pesquisa, a base de dados e o planejamento metodológico. Na segunda etapa, esse planejamento foi efetivamente implementado por meio da construção de um pipeline de dados, criação de uma camada de staging em banco relacional e desenvolvimento de consultas analíticas voltadas à identificação de desigualdades estruturais no sistema educacional.

As análises realizadas evidenciam que ainda existem diferenças relevantes na disponibilidade de infraestrutura escolar entre regiões do país, bem como entre diferentes tipos de rede de ensino. Esses resultados demonstram que fatores estruturais continuam influenciando as condições de ensino oferecidas aos estudantes e reforçam a importância de políticas públicas orientadas por evidências.

Dessa forma, o projeto demonstra como técnicas de ETL e análise de dados podem ser aplicadas para transformar microdados educacionais em informações estratégicas, contribuindo para diagnósticos mais precisos e para o apoio à tomada de decisão no campo das políticas educacionais.

REFERÊNCIAS

- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). **Microdados do Censo Escolar**. Brasília, DF: INEP, 2024. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-escolar>. Acesso em: 11 nov. 2025.
- BRASIL. Ministério da Educação (MEC). **Censo Escolar da Educação Básica: notas estatísticas 2024**. Brasília, DF: MEC/INEP, 2024. Disponível em: <https://www.gov.br/inep>. Acesso em: 11 nov. 2025.
- INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Indicadores de Desigualdade e Pobreza no Brasil**. Rio de Janeiro: IBGE, 2023. Disponível em: <https://www.ibge.gov.br>. Acesso em: 11 nov. 2025.
- SOARES, José Francisco; ALVES, Maria Teresa Gonzaga. **Desigualdades educacionais no Brasil: o papel das condições escolares**. Educação e Pesquisa, São Paulo, v. 38, n. 1, p. 13-28, 2012. DOI: 10.1590/S1517-97022012000100002.
- UNESCO. **Relatório de Monitoramento Global da Educação 2023/2024: a educação sob pressão – desigualdades e financiamento público**. Paris: UNESCO, 2024. Disponível em: <https://unesdoc.unesco.org>. Acesso em: 11 nov. 2025.